

电 子 科 技 大 学

UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

学士学位论文

BACHELOR THESIS



论文题目 深度学习在阵列诊断中的运用

学 院 格拉斯哥学院

专 业 电子信息工程

学 号 2015200101031

作者姓名 王骏飞

指导教师 张瑛 副教授

摘 要

阵列天线因为具有快速波束扫描,高功率,高增益等等特征,在现代雷达设备中得到了普遍的应用。由于阵列天线结构复杂,在各种极端环境中,阵元的更换和维修不是很容易。因此,研究阵元失诊断算法,在有限的条件下快速定位失效阵元的位置就显得尤其重要。

近场诊断方法是当前最常用的阵列诊断方法之一。但是近场扫描一般在测量与收集数据上非常耗时,且需要收集不少的数据,并且对于某些特定应用场景,有时是禁止进行近场扫描的。因此,仅由天线阵列的远场数据来诊断失效阵元是非常重要的。

本文首先分析研究了常见的阵列故障诊断算法,然后提出了一种基于深度迁移学习的阵列诊断措施。该方法将源域的知识从训练后的诊断模型迁移到其他结构不同的阵列,在运用少量训练数据的同时加快了诊断模型的训练速度,并保持令人满意的诊断准确性。首先,将基于深度神经网络(DNN)的阵列故障诊断模型作为基础模型进行训练;其次,通过将目标域划分为几个子域并多次重用基本模型,从而构建了用于其他阵列失效阵元诊断的端到端的深度迁移网络。然后,使用目标域的少量远域辐射数据仔细调整诊断模型的参数。最后,在计算机上使用仿真软件验证了所提方法的有效性和可行性。

关键词: 阵列诊断, 深度学习, 远域, 迁移学习, 方向图数据

ABSTRACT

Array antennas are widely used in modern radar equipment due to their high power, high gain, and fast beam scanning. The structure of the array antenna is complex, and the failure of the array element is not easy to replace and repair, especially in aerospace, battlefield and other application environments. Therefore, it is particularly important to analyze the effect of the failed array element on the performance of the array antenna and to quickly locate the failed array element under limited conditions.

The current common method for array diagnosis is to use near-field diagnosis. However, near-field scanning generally requires more data to be collected, the measurement and data processing time is longer, and for different application environments, sometimes near-field scanning is not possible. Therefore, it is of great significance to study how to diagnose the failed array element in the phased array antenna only through the data of the far-field amplitude pattern, and then calibrate the array after the array element fails.

This paper first analyzes and studies common array failing elements diagnosis algorithms, and then proposes an array diagnosis method based on deep transfer learning, which transfers knowledge from the trained diagnosis model to other arrays with different structures to accelerate diagnosis model training using a small set of training data and maintain satisfactory diagnosis accuracy. Firstly, an array failure diagnosis model based on DNN is trained as the base model. Secondly, an end-to-end deep transfer network is built for failure diagnosis of other arrays by dividing target domain into several sub-domains and reusing the base model multiple times. Then, the parameters of the diagnosis model are carefully tuned using small far-field radiation data of target domain. Finally, computer simulations are conducted to verify validity and superiority of the proposed method.

Key words: Array diagnosis, deep learning, far-field, radiation data, transfer learning.

目 录

第一章 绪论.....	6
1.1 研究背景与意义	6
1.2 国内外研究现状	6
1.3 本文研究内容与安排.....	7
第二章 深度学习基础.....	8
2.1 机器学习发展历程与应用	8
2.2 深度学习理论与人工神经网络	9
2.3 激活函数.....	10
2.4 代价函数.....	11
2.5 多层神经网络与后向传播规则	12
2.6 深度学习的应用	13
第三章 常见阵列故障诊断算法.....	14
3.1 引言.....	14
3.2 基本遗传算法原理.....	14
3.3 建立适应度函数	15
3.4 自适应遗传算法	16
3.5 阵元失效影响分析.....	17
第四章 基于迁移学习的阵列故障.....	20
4.1 引言.....	20
4.2 迁移学习原理与在阵列诊断中的应用.....	20
4.3 类别编码和故障模型.....	21
4.4 神经网络训练中的优化算法	22
4.4.1 梯度下降算法.....	22
4.4.2 小批量梯度下降算法.....	22
4.4.3 自适应矩估计算法.....	23
4.3 线性阵列诊断模型建模.....	24
4.4 深度迁移网络的构建.....	25
4.5 模型可视化	26
4.6 评估测试.....	28
第五章 研究工作总结.....	33
致谢.....	34
参考文献.....	35

外文资料原文.....	37
外文资料译文.....	38

第一章 绪论

1.1 研究背景与意义

由于阵列天线具有的高功率，高增益，快束扫描等其它特征已被广泛用于现代雷达设备^[13]。阵列天线系统构造复杂，在某些极端情况下阵元容易出现失效，由此引起天线方向图，旁瓣电平性能指标衰减，甚至影响天线的正常使用^[15]。因此，分析系统失效阵元对阵列天线辐射性能的影响，在有限的条件下快速诊断出失效阵元的位置并替换，就是当前尤其重要的任务。

对于一个不大的天线阵列，考虑到型号大小，成本的原因，我们通常不会安装校准系统；但在大型有源相控阵天线阵列中，校准系统可以是各种内嵌或监控设备^[14]。

在没有校准系统的情况下，我们只能依靠外部数据来确定故障组件的位置。近场诊断法通过测量阵列天线近场的幅度和相位等有关数据，再利用存在于近场和远场间的傅里叶变换关系，得出该阵列的远场方向图的幅度和相位信息^[16-17]。知道这些信息后，天线的阵列分布就能通过反演而轻易的得出，从而实现天线的诊断。但是，近场扫描需要采集不少的数据，且近场采集不容易数据处理还耗时。对于失效阵元的位置，如果仅能通过测量远场方向图的数据来得出，则是一个省时省力的完美方式

1.2 国内外研究现状

许多学者和专家进行了大量的分析和实验来验证使用远场方向图诊断阵列的可行性和相比于近场诊断的优越性。

在 2005 年，王玲玲通过引入傅里叶变换中变换域与角域之间的映射关系，提出了一种结合遗传算法和快速傅里叶变换方法来校正失效后的阵列元件的方法^[18]。该方法使用快速傅里叶变换来计算单个阵列的阵因子，大大降低了遗传算法评估个体的时间，相应的失效校准速率也有所提升。

2007 年，NanXu 等人从不同的天线阵列结构提取远场方向图数据作为输入特征，使用支持向量机（SVM）对 4 元均匀线阵进行阵列诊断^[19]。通常，SVM 分类器是最常用的机器学习优化算法之一，在阵列诊断中，通常把测得的远场方向图数据作为输入特征向量以此进行训练^[20]。

2010 年，ARMallahzadeh 和 M. Taherzadeh 还使用 MLP 人工神经网络来诊断 6x6 微带贴片天线阵列的故障阵列元件。然而仿真的失效情况数任然高达 667 次^[21]。

汪一心分析了阵列天线因单或多单元故障引起的旁瓣恶化和增益损失。BFGS 优化算法用于优化失效元件附近的一些正常元件的幅度和相位^[22]，对于旁瓣电平指数的下降具有一定的补偿作用。

高铁基于原有的对故障单元的线性规划以及矩形切割方法，提出了一种仅对非失效单元的幅度进行了调整，可以适用于多单元失效后激励分布的补偿的新想法。该方法在失效补偿后先恢复两个副瓣的性能，之后利用线性布局方法对整个空间内的均匀副瓣进行优化^[23]。

2013 年，边莉等人提出了一种基于交叉熵全局随机优化算法的改进的交叉熵算法，以解决泰勒双阵列单元的失效问题^[24]。

1.3 本文研究内容与安排

本文从阵列天线和深度学习的基本理论出发，分析并模拟了天线阵列中阵列元件对阵列辐射性能的影响，并比较分析了基于远场的各种诊断阵列元件故障的方法；最后决定采用基于机器学习的诊断方法，同时针对机器学习通常需要大量标记数据的特点，引入了迁移学习的内容来改进训练模型，从而在只需要较少的标记数据下，保持了令人满意的精确度。具体安排如下：

第一章：介绍了国内外对阵列天线失效阵元诊断的方法和研究，同时给出了本论文的章节安排以及主要工作内容。

第二章：简要介绍了机器学习的发展历程以及深度学习的基本理论以及影响，为后续阵列诊断模型建模提供了指导。

第三章：基于天线阵列理论，分析了常见的阵列失效诊断算法。

第四章：简要概述了迁移学习的原理，并利用迁移学习的知识对诊断模型进行了建模与仿真，最后分析了目标模型与源模型的各项性能指标，验证了迁移学习在远场方向图诊断失效阵元的方法中相比于传统机器学习的优越性。

第五章：总结了本文的工作和研究内容，以及对未来工作的思考和目前需要克服的问题。

第二章 深度学习基础

2.1 机器学习发展历程与应用

早在几千年之间，机器学习的想法就已出现。当时的人们幻想机械装置也能像人一样有各种表达，直到 17 世纪拉普拉斯提出马尔科夫链，贝叶斯总结了最小二乘法；机器学习的雏形才开始诞生。到了 20 世纪中旬，Allen Turing 提出了建造学习机器的构想，但直到 21 世纪初，因为各种物理界限的突破，比如算力提升，数据量增大，深度学习才有才有了巨大的发展和实际运用。

从 20 世纪中旬艾伦图灵提出建造学习机器的构想开始，直到今天，机器学习大致走过了四个阶段，不同阶段的目的和研究方向一般不同。

从 20 艾伦图灵提出学习机器构想一直到 60 年代中期为第一阶段。这一时期，主要提出了通过知识来学习的构想，主要是围绕“知识是否能让机器学习”的问题。打个比方，比如更改一个学习机器的参数，或者更改其输入数据，系统是否能自动更改自身的属性以达到最佳状态。

第二阶段是从 1960 年代中期到 1970 年代中期。图结构和逻辑结构的知识被应用到机器学习的理论和系统之中，人们开始比较和模拟机器与人的学习过程，力图通过人的思考和行为将知识整合到学习机器的系统里，从而实现智能化。

从 1970 年代中期到 1980 年代中期的第三阶段称为机器学习的繁荣时期。随着个人计算机的普及，越来越多的人开始接触机器学习，各种机器学习的算法和策略有被提出和发表，并且开始尝试将学习系统应用到实际生活中。1980 年，第一届国际机器学习会议（CMU）在美国卡内基梅隆大学举行，从此机器学习成为了一个世界范围的研究课题。

80 年代中期直到现在，为机器学习的第四阶段即最新阶段，在此期间的机器学习具有以下特征：

（1）机器学习成为众多学科中冉冉升起的一颗新星，它的基础理论众多且复杂，涉及生物学，数学，计算机科学等主要领域。

（2）各种机器学习理论一直在不停的更新和发展，越来越多的学科知识被融入到机器学习中。

（3）机器学习发展过程中，难免会遇见分歧与不同的观点，但总体上，对基本问题的看法正在趋于一致。

（4）机器学习越来越融入到人们的生活当中，越来越多的领域尝试运用机器学习来解决问题，部分研究成果已经可以形成有价值的产业链。

机器学习的研究主要分为两个分支：第一种为传统方法下的研究，主要通过观察人与机器的差别，探索人与机器学习机制的异同，从而归纳机器学习的方法。

第二种方法出现较晚，随着大数据的普及，这种类型的研究才渐渐出现；这类研究重点不在于学习系统，而在于如何从海量数据中提取隐藏的特征，从而提升学习系统的性能。直到今天，机器学习已经应用于自然语言处理，人脸识别，医疗诊断等诸多领域，已经不仅仅应用于基本的知识系统中。

2.2 深度学习理论与人工神经网络

深度学习是一类模式分析法的统称，按常理主要分为三类方法：

(1) 第一类是发源于卷积运算的神经网络，即卷积神经网络（CNN）。

(2) 自编码（Auto encoder）以及稀疏编码两类（Sparse Coding），都是源于多层神经元的网络系统

(3) 通过多层自编码的形式进行预训练，结合辨别信息再优化神经网络偏执与权值的深度置信网络（DBN）。

深度学习最初源于人们对人工神经网络的研究，人工神经网络模拟人脑运行的机制，通过多个神经元来解释各种类型数据的运算，例如接受各种反馈（声音，图像，文本）。当神经网络中神经元过多，需要多层感知时，来对人脑进行更深层的模拟时，深度学习应运而生。本质上说，深度学习就是神经网络有多个隐层的情况，其将模糊的特征组合过滤为更抽象的高级特征，使得机器学习的训练更加容易。

可以通过流向图表示从输入生成输出所涉及的计算：流向图（flow graph）是一种可以表示计算流程的图，由输入节点，计算节点，输出节点组成。其中输入节点是最初的节点，没有比它更前面的节点，输出节点是最后一个节点，没有比它更后面的节点。每个节点包含基本的计算，可以是线性或者非线性，节点的输出将传递给下一个节点，从而形成神经网络的结构。一般来说，流向图的一个最重要的属性是深度（depth），深度表示一个神经网络的最长路径，即从输入层到输出层。传统前馈神经网络的深度可以等于层数。含多个隐层的深度神经网络如图 2-1 所示。




图 2-1 含多个隐层的深度学习模型

2.3 激活函数

激活函数 (Activation Function)，顾名思义，就是为了使得神经元运行起来的函数，假设一个神经元，其输入经过该神经元后得出一个输出；如果没有激活函数，那么该神经元就是线性的，输入将等于输出，没有任何变化，因此激活函数就是使得神经元变为非线性，使得输入信息产生变化。常见的激活函数有：

1) Sigmoid 函数

Sigmoid 函数是一个在信息学中常见的形状为 S 型的函数，常被称为神经网络的阈值函数，运用于二分类问题中；因为该函数随着自变量的增加而单调递增且只将输出映射到 $[0,1]$ 之间的任何值。当输入为 0 时，输出恰好等于 0.5；输出最大只能无限逼近于 1。公式如下：

$$\Phi(v_i) = \frac{1}{1+e^{-v_i}} \quad (2-1)$$

其导数表达式为：

$$\varphi'(v_i) = \varphi(v_i)(1 - \varphi(v_i)) \quad (2-2)$$

函数如图 2-2 所示。




图 2-2 Sigmoid 激活函数

2) Softmax 激活函数

在机器学习中的多分类问题中，常常需要使得输出的归一化和为 1，这样输出层的每个神经元的输出就为该分类的概率，概率之和正好为 1，这也就把输出层的每个神经元相互联系了起来。Softmax 就是这样一种函数，可以使得输出层节点输出之和刚好为 1。输出采用单热编码方式（只有一位为 1 其他位为 0）。公式如下：

$$\varphi(v_i) = \frac{e^{v_i}}{e^{v_1} + e^{v_2} + e^{v_3} + \dots + e^{v_M}} \quad (M: \text{输出节点个数}) \quad (2-3)$$

3) Relu 激活函数

相比于其他激活函数，Relu 激活函数具有更加有效率的梯度下降以及反向传播；从而避免了梯度爆炸以及梯度消失问题。公式如下：

$$\varphi(k) = \max(0, x) \quad (2-4)$$

函数图如图 2-3 所示




图 2-3 ReLU 激活函数

2.4 代价函数

代价函数（cost function）通常用来衡量某个量偏离期望值的程度，神经网络的训练目标就是使代价函数最小，其决定具体的学习规则。

常用的代价函数有两类：

1) 交叉熵代价函数表达式为：

$$J = \sum_{i=1}^M \{-d_i \ln(y_i) - (1 - d_i) \ln(1 - y_i)\} \quad (d = 0 \text{ 或 } 1) \quad (2-5)$$

如图 2-4 所示。




图 2-4 交叉熵代价函数

2) 平方和代价函数表达式为:

$$J = \sum_{i=1}^M (d_i - y_i)^2 \quad (2-6)$$

如图 2-5 所示。




图 2-5 平方和代价函数

对比两图可以得知，与平方和代价函数相比，交叉熵代价函数中随着 y 偏离 d ，其误差增长速率更快。也就是说，交叉熵代价函数对误差更敏感，其学习速率明显优于误差平方和。

总的来说，代价函数+激活函数决定权值系数更新算法；学习规则是对经典组合下更新算法的固化。

2.5 多层神经网络与后向传播规则

反向传播算法（Back-Propagation）是专用于多层神经网络的一种算法，它起因于单层神经网络不能很好的拟合模型。因此在梯度下降算法的基础上，衍生出基于多层神经网络的反向传播算法。BP 神经网络本质上是对前向传播算法的一种再归纳和再总结，在前向传播算法中，神经网络的本质就是通过梯度的计算

来更新权值。它对信息的处理能力来自对非线性函数的多次组合，因此具备有很强的再现函数的能力。这是可以应用 BP 算法的基础。

因为单层神经网络为线性模型，只能解决线性可分问题，因此需要多层神经网络来解决线性不可分的问题。在多层神经网络中，通常使用后向传播算法作为学习规则。其中反向传播误差表达式为：

$$\delta = \varphi'(v_i) \times e \quad (2-7)$$

后向传播过程如图 2-6 所示。




图 2-6 后向传播示例

BP 算法下的监督学习基本步骤：

- Step1: 初始化权值系数
- Step2: 提取一个训练样本 $\{x, y\}$ ，计算网络输出与期望输出之差 $(e = d - y)$ ，以及输出节点的 delta $(\delta = \varphi'(v_i)e)$
- Step3: 向后传播输出节点的 delta，计算上一层节点的 delta 传播表达式为：

$$e^k = W^T \delta$$

$$\delta^k = \varphi'(v^{(k)})e^{(k)}$$

- Step4: 重复 Step3 至抵达第一隐含层
- Step5: 调整各层权值系数
- Step6: 重复 Step2-5 遍历每个训练样本
- Step7: 重复 Step2-6 直到输出误差符合预期

2.6 深度学习的应用

深度学习在搜索引擎，医疗诊断，数据挖掘，智能翻译，虚拟现实，多媒体学习，语义识别，以及其他相关领域中取得了许多成果。深度学习使机器能够模仿诸如视听和思维之类的人类活动，解决了许多复杂的模式识别问题，并在人工智能相关技术方面取得了长足的进步。

第三章 常见阵列故障诊断算法

3.1 引言

阵列天线是一种天线系统，包括许多按一定规则组合的单个天线，天线阵的独立进行单元可以称为阵元或天线结构单元。如果阵列元素被布置成一条线或一个平面，它就是一个线性阵列或平面阵列。

阵列天线因大功率、高增益、快速进行波束扫描等特点，而被广泛研究应用于中国现代雷达技术装备。阵列天线的元件是否故障决定了雷达的综合性能；因此，能否快速诊断天线阵列中失效阵元的数目和位置就成了雷达系统中的重中之重。当今对于相控阵天线有关的检测研究主要分为以下三类：

- 1) 调制控制，换相测量方法，将信号从低频通道移动到高频通道进行传输，从而加快了诊断速度^[25,26]。
- 2) 全息成像法，无相位测量和矢量测量^[27]是全息成像法的主要依靠，通过这两种测量，可以准确得到阵元的幅度分布和相位分布。
- 3) 模式识别法，将样本特征进行分类，从而实现故障单元的精准定位^[28,29]

因此，在保证阵列天线性能的前提下进行阵列失效阵元的位置定位，就显得尤为重要。本章将介绍常见的阵元失效诊断算法——遗传算法，用于阵列的故障诊断。利用遗传算法寻找最接近测量模式的阵列激励，然后构造目标函数所代表的不同条件下的阵列模式与测量模式之间的不同，以找到失效阵列的位置和数量。

3.2 基本遗传算法原理

遗传算法（GA）由约翰·霍兰德（John Holland）教授于 1975 年提出，该算法通过模拟达尔文提出的所谓“适者生存”模型，对种群中个体实行选择，交叉，变异三个遗传运算的迭代，让其朝着自适应性的方向进化，从而获得适合目标的个体。遗传算法有以下优点^[30]：

- (1) 传统算法从单个初始值迭代的搜索最优解，容易找到局部最优解。遗传算法从字符串集开始，覆盖范围相比前者更宽，更容易避免陷入局部最优。可以说初始值的差异是遗传算法与传统算法最主要不同。
- (2) 通常遗传算法的初始字符串来自于多个信息源，它从一个包含许多个体的初始种群开始，重复运算搜索迭代，从而找到最佳的解决方案，这与传统的从单个初始点开始进行搜索的优化算法不同
- (3) 在遗传算法中，适应度函数是唯一评估标准，至于其他辅助信息，如搜索空间中的知识，基本都不需要，适应度函数自由度高，可自定义域范

围与变量，因此遗传算法可应用于多种场景之中。

- (4) 遗传算法以字符串编码为操作对象，通常是对决策变量进行编码，而传统的优化算法只用决策变量的单个数值进行运算，这种编码方式是受生物学中生物进化和遗传的启发，决策变量就相当于生物学中的染色体，能分裂和变异。

基本遗传算法是由 D.J.Goldberg 总结的一种算法，其只包含遗传算法中最基本的操作步骤。选择-复制，交叉和变异为基本遗传算法的基本操作。选择操作是作用于种群的选择操作符，可以通过配对产生新的个体，也可以直接把优化后的个体传递给下一代。个体适应度的评估表现决定了选择操作。通过交叉运算，交叉算子将在群体中起重要作用。变异算子作用于群体简称为变异运算；即是对群体中的个体串的某个基因位点上的基因值作一定的变化。群体 $P(t)$ 经过选择、交叉、变异运算之后得到下一代群体 $P(t+1)$ 。

算法的控制参数包括种群规模(p)，最大换代数，变异概率(p_c)，适应度函数(f)。遗传算法的基本运算步骤如图：

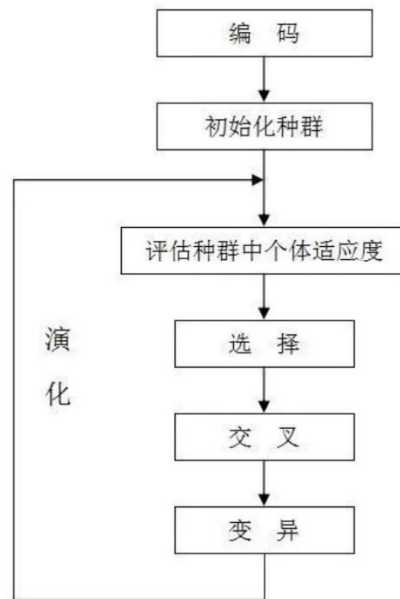


图 3-1 遗传算法基本步骤

3.3 建立适应度函数

把阵元的状态分为工作状态和非工作状态，并把阵元的两种工作状态使用遗传算法进行编码。根据二进制表示，可用 1 代表阵元正常工作，否则为失效，用于构建诊断失效阵元所需的目标函数。

对于阵元相同间距相同激励的 N 元线阵方向图可以表示为

$$E(\theta, \phi) = f(\theta, \phi) \cdot \sum_{n=1}^N I_n \exp[jk \sin \theta (x_n \cos \phi + y \sin \theta)] \quad (3-1)$$

其中 $f(\theta, \phi)$ 是单元方向图， I_n 是 N 元阵的激励。

在远场选取 M 个采样点，实测远场方向图为 $P_M(\theta_i, \phi_i)$ ，阵元处于编码状态下在对应采样点位置的远场方向图为 $P_{chr}(\theta_i, \phi_i)$ 。构建函数

$$\xi = \sum_{i=1}^M \omega \cdot [\overline{F_{chr}}(\theta_i, \phi_i) - \overline{F_M}(\theta_i, \phi_i)]^2 + \sum_{j=1}^N \gamma \cdot |\theta_{jchr} - \theta_N| \quad (3-2)$$

将远场方向图幅度用 dB 表示为

$$F(\theta, \phi) = 20 \cdot \log_{10} |E(\theta, \phi)| \quad (3-3)$$

其中 $\overline{F_{chr}}(\theta_i, \phi_i)$ 和 $\overline{F_M}(\theta_i, \phi_i)$ 分别表示对 $F_{chr}(\theta_i, \phi_i)$ 和 $F_M(\theta_i, \phi_i)$ 进行归一化后的方向图。计算阵元处于不同编码情况下在对应采样点位置的远场方向图，同时实测远场方向图 $F_{chr}(\theta_i, \phi_i)$ ， θ 是零陷位置的度数。对于故障元件的位置和数量，可以使用遗传算法对上式进行优化迭代，当对应差值为最小值时，获得对应的阵元编码情况。

然而在实测中，该方法存在以下问题。

对于对称的激励阵列，这种方法无法分辨出对称位置造成的失效。单一遗传算法编码不能完全表达优化问题的约束条件，用约束的一个方法就采用阈值来应对无用解，但耗时必定增加。其次，不完美的适应度函数也间接导致了遗传算法的过早收敛，因而，遗传算法的效率一般比其它传统的优化方法效率低。

对于上述问题，可以通过优化遗传算法进而解决，防止其陷入局部收敛。

3.4 自适应遗传算法

遗传算法是一种随机优化算法，其起源于生物学的自然进化过程，在寻找全局最优解时相比于其他算法具有更好的适应性与稳定性，不容易发生偏移。但在实际过程中，因为问题可能比较复杂，因此遗传算法不能很好的整合搜索信息，导致了搜索速度比较慢，甚至有时候会误入歧途，陷入“早熟”陷阱。

在遗传算法的基础上，许多学者专家对其进行了改良，自适应遗传算法(AGA)得以出现。在传统遗传算法中，遗传参数都是不变的，但在自适应遗传算法中，遗传参数能根据搜索情况自动调整从而达到收敛的最佳状态，从而提高了收敛精度。在快速收敛的同时，因为遗传参数的自适应性，种群的多样性也得以保留。因此，自适应遗传算法能提高基本遗传算法的收敛速度和收敛精度^[31]。

在自适应遗传算法中，种群中个体的适应度变化直接影响着交叉概率 P_c 和变异概率 P_m ；当种群适应度改变，变异概率与交叉概率也随之改变。增大 P_c 和 P_m ，

可以增加跳出局部最优的概率；减小 P_c 和 P_m ，有利于优良个体的生存。

在自适应遗传算法中， P_c 和 P_m 按照以下公式调整：

$$P_c = \begin{cases} \frac{k_1(f_{\max} - f')}{f_{\max} - f_{\text{avg}}}, & f' > f_{\text{avg}} \\ k_2, & f' \leq f_{\text{avg}} \end{cases} \quad (3-4)$$

$$P_m = \begin{cases} \frac{k_3(f_{\max} - f')}{f_{\max} - f_{\text{avg}}}, & f' > f_{\text{avg}} \\ k_4, & f' \leq f_{\text{avg}} \end{cases} \quad (3-5)$$

式中， f_{avg} 代表每代种群的所有个体的平均适应度； f 表示需要变异个体适应度； f_{\max} 表示种群中个体最大的适应度； f' 表示需要交叉的两个个体适应度比较大的值。

然而，此算法在进化初期时，和有可能因为个体适应度接近最大适应度，而导致其等于 0，这是十分不利的，容易造成局部最小值。为了克服此瑕疵，一种改进过后的自适应遗传算法被提出^[32]。

$$P_c = \begin{cases} P_{c1} - \frac{(P_{c1} - P_{c2})(f' - f_{\text{avg}})}{f_{\max} - f_{\text{avg}}}, & f' > f_{\text{avg}} \\ P_{c1}, & f' \leq f_{\text{avg}} \end{cases} \quad (3-6)$$

$$P_m = \begin{cases} P_{m1} - \frac{(P_{m1} - P_{m2})(f' - f_{\text{avg}})}{f_{\max} - f_{\text{avg}}}, & f' > f_{\text{avg}} \\ P_{m1}, & f' \leq f_{\text{avg}} \end{cases} \quad (3-7)$$

从式 3-6, 3-7 可得出，对算法进行改进后，种群中适应度最大的个体交叉概率和变异概率分别为 P_{c2} 和 P_{m2} ，避免了局部收敛的情况，从而使得优良个体不会处于停滞状态。

同时也可使用精英保留策略，把群体在进化过程中迄今出现的最好个体(称为精英个体 elitist)不进行配对交叉而直接复制到下一代中。从而保证了适应度最高的个体不会被破坏。

3.5 阵元失效影响分析

本节采用了 8x8 的切比雪夫平面阵列来分析不同阵元失效情况对阵列远场幅度方向图的影响，因为失效的情况很多，不能一一列举，因此选取了两种典型的多阵元失效模式如图 3-2 所示。




图 3-2 4 单元失效情况

图 3-3 为 4 个失效阵元的模式图，其分别表示密集分布于阵列中心和阵列一端的情况。




图 3-3 多阵元不同位置失效方向图

由图 3-3 可以看出，失效阵列方向图约等于无干扰阵列方向图和失效阵元组成的阵列方向图的叠加，相应的，失效阵元的位置影响了旁瓣的特性并改变了其零陷位置，因此抗干扰能力减弱。

对于单阵元失效情况，从下图 3-4 可看出阵元失效下方向图副瓣电平升高，且失效阵元位置越靠近中心，旁瓣电平越高。

综合多阵元与单阵元失效情况分析可得，在两类不同失效情况中，多阵元故障对天线远场辐射性能的影响大于单阵元故障对其的影响。不同的单阵元故障导致旁瓣的变化也有所不同。在方向图中，主瓣区域基本没有变动，并且辐射特性基本不变；但是，对旁瓣的影响更大，旁瓣水平变化很大，并且零陷的位置也发生了变化。阵列元件的故障将导致阵列天线的增益略微下降，并且阵列元件在中心位置处的故障对场辐射特性的影响明显大于天线边缘上阵列元件的故障影响。也就是说，失效元件越靠近中心，影响效果就越大。




图 3-4 单阵元失效下的方向图

第四章 基于迁移学习的阵列故障

4.1 引言

阵列元件的失效概率随着阵列尺寸的增加而增加,从而导致天线性能的下降;阵列失效诊断旨在找出失效阵元的位置。近年来,许多阵列诊断技术有被研究[1,2,3,4,5],但基于机器学习的诊断方法受到了广泛的关注。以阵列的远场辐射方向图为特征,以失效阵元的位置为标记,可以训练分类器用机器学习的方法确定被测天线阵列的失效元件的位置。基于支持向量机(SVM)的阵列失效诊断方法曾被提出,其中失效场景用二进制代码表示。但是,失效场景的数量随着阵元的增加而呈指数增长,导致诊断准确性下降。人工神经网络(ANN)也用于从方向图提取有效特征并确定失效元件的位置^[6]。




图 4-1 传统分类器分类流程

但是,基于 ANN 的现有方法仅适用于元素很少的数组。由于训练一个分类器总是需要一定数量的不同辐射方向图,这些方向图对应于不同的失效情况,因此训练每个天线阵列的分类器很消耗时间,但上述方法通过训练所有可能的失效情况都获得了很高的诊断准确性。假设具有不同结构的天线阵列的诊断模型都具有一定的关系,本章尝试将知识从已训练好的诊断模型迁移到另一种不同结构的诊断模型中,以减少训练数据并提高诊断准确性。

本章将首先介绍迁移学习原理与在阵列诊断中的运用,然后简要介绍分类器的输出形式,接着介绍一下常用到的有关神经网络的优化算法,最后通过建模仿真验证该方法的有效性。

4.2 迁移学习原理与在阵列诊断中的应用

迁移学习是一种新的机器学习方法,它利用已有的知识解决不同但相关的领域问题。与传统机器学习不同,迁移学习旨在用源域已有的知识来解决目标领域标记数据量小甚至没有数据的问题。迁移学习在深度学习中普遍的被使用,两个不同的领域信息共享的因素越多,迁移就越容易,否则就越困难,甚至可能出现负迁移^[10]。进行深度迁移学习一般有两种方法,一种为开发模型方法,另一种为

预训练模型方法^[12]；后者在深度学习领域比较常用，但在此课题中将运用开发模型方法，具体步骤为：

- (1) 选择源任务。源任务需与目标任务之间由某种相关且紧密的联系，因为信息共享的因素越多，迁移就越容易，模型也就容易共享。
- (2) 开发源模型。根据源任务，制作一个模型。这个模型应该可以被目标任务所调用，且模型的精确度要有所保证。
- (3) 重用模型。目标任务重用该源模型，根据需要也可以对源模型做适当的修改，使其更好的适配于目标任务。
- (4) 调整模型。对重用后的模型权值进行适当性的微调，使其完全匹配目标任务的输入与输出。

深度迁移学习已应用于各种领域，例如医疗疾病诊断，交通流量控制和人类活动识别。在这些基于模型的深度迁移学习方法中，源域和目标域的特征具有相同或相似的维度；由于结构不同的阵列的辐射方向图的特征存在很大的差异，因此不能直接用于阵列失效阵元的诊断。该问题通过划分目标域来解决。首先，给出了用于线性阵列故障诊断的 DNN，将其作为源模型来帮助训练其他复杂阵列的诊断模型；其次，提出了一种端到端的深度迁移神经网络构架，以在少量训练数据的情况下实现失效阵元的诊断。与传统的机器学习方法相比，迁移学习在失效阵元诊断方面只用了少量的训练数据并保持了令人满意的准确性。

4.3 类别编码和故障模型

本文只考虑天线阵列中最常见的阵元失效，在基于模式识别的失效阵元诊断方法中，阵元通常只有工作和失效两种状态。对应阵元数量为 n 的阵列天线，本文用 N 维向量来表达阵元的工作状态。若第 i 个阵元失效，则 $n_i = 0$ ，否则 $n_i = 1$ 。

对于分类器来说，需将故障模式转换为分类器容易输出的形式，通常为线性模式。首先将所有需要考虑故障模式编号，编号为类别值，即 0 或 1。将向量 n 转为二进制数的故障编码，再将故障编码排序，利用单热编码将故障模式的类别值转为分类器的理想线性输出形式，即计算机容易利用的形式。全连接神经网络作为分类器时的理想输出就是单热编码形式的值。




图 4-2 故障编码

本文中选取 8x8 的共 64 阵元的平面阵列天线作为仿真参数，因此分类器理想输出应为 64 维的向量，向量中 1 表示阵元工作，0 表示失效。

4.4 神经网络训练中的优化算法

神经网络中经常使用基于梯度的优化算法，常用的有梯度下降算法(BGD)，小批量梯度下降算法(MBGD)，自适应矩估计等算法(Adam)。本节将介绍这三种常用的优化算法，但在本文建模仿真中，主要应用自适应矩估计算法。

4.4.1 梯度下降算法

在深度学习中，为了得到最小化的代价函数和最优化的模型参数，通常采用梯度下降算法重复的迭代求解。对于目标函数为 $f(\theta)$ 的最优化问题，计算步骤为：

- (1) 选取初始点 θ_0 ，并给定预设阈值 ϵ 与学习率 l ，记录当前迭代步数 $k = 0$;
- (2) 计算梯度

$$g_k = \nabla f(\theta_k) \quad (4-1)$$

若 g_k 的绝对值小于预设阈值 ϵ ，终止迭代并输出 θ_k ，否则执行 (3)

- (3) 更新参数 $\theta_{k+1} = \theta_k + lg_k$ ，跳转 (2)。

采用梯度下降算法进行最优化求解时，终止条件可以通过设置 epoch 来代替，当然也可以设置一个常数阈值。

4.4.2 小批量梯度下降算法

监督学习中，代价函数作为目标函数的最重要部分通常写为所有样本代价函数之和的平均值

$$J(\theta) = \frac{1}{N} \sum_{i=1}^N L(x_i, y_i, \theta) \quad (4-2)$$

x_i 为预测值， y_i 为标签， L 为损失函数的算子， N 为总的样本数， θ 为神经网络中可训练的权值。

在小批量梯度下降中，把数据分为若干个批，每个按批来更新权值，这样，一个批中的一组数据共同决定了本次梯度的方向，下降起来就不容易跑偏，减少了随机性。

从训练集中均匀抽取小批量样本，样本数量为 N^1 ，梯度可以表达为

$$g = \frac{1}{N^1} = \sum_{i=1}^{N^1} \nabla_{\theta} L(x_i, y_i, \theta) \quad (4-3)$$

小批量梯度下降算法步骤为：

- (1) 选取初始点 θ_0 ，并给定预设阈值 ϵ 与学习率 l ，记录当前迭代步数 $k = 0$ ；
- (2) 计算每个小批量梯度的期望 $g = \frac{1}{N^1} = \sum_{i=1}^{N^1} \nabla_{\theta} L(x_i, y_i, \theta)$
- (3) 更新权值参数 $\theta_{k+1} = \theta_k + lg_k$
- (4) 若满足终止条件，输出结果并结束，否则跳转步骤 2。

4.4.3 自适应矩估计算法

自适应矩估计算法本质上是带有动量项的 RMSprop(root mean square prop)，它利用梯度的一阶矩估计和二阶矩估计动态调整每个参数的学习率。自适应矩算法的优点主要在于经过偏置校正后，每一次迭代学习率都有个确定范围，使得参数比较平稳。其主要步骤为：

- (1) 设置步长 ϵ (默认为 0.001)，矩估计的指数衰减速率 ρ_1 和 ρ_2 在区间 $[0,1]$ 内(默认分别为 0.9 和 0.999)，用于数值稳定的常数 δ (默认为 10^{-8})，初始参数 θ ，初始一阶和二阶矩变量 $s=0, r=0$ ，初始时间步 $t=0$ 。
- (2) 从训练集中采集包含 m 个样本 $\{x^{(1)}, \dots, x^{(m)}\}$ 的小批量，对应目标为 $y^{(i)}$ 。计算梯度：

$$g \leftarrow \frac{1}{m} \nabla_{\theta} \sum_i L(f(x^{(i)}; \theta), y^{(i)}) \quad (4-4)$$

然后 $t \leftarrow t + 1$

- (3) 更新有偏一阶矩估计： $s \leftarrow \rho_1 s + (1 - \rho_1)g$
- (4) 更新有偏二阶矩估计： $r \leftarrow \rho_2 r + (1 - \rho_2)g \odot g$
- (5) 修正一阶矩的偏差： $\hat{s} \leftarrow \frac{s}{1 - \rho_1^t}$
- (6) 修正二阶矩的偏差： $\hat{r} \leftarrow \frac{r}{1 - \rho_2^t}$
- (7) 计算更新： $\Delta\theta = -\epsilon \frac{\hat{s}}{\sqrt{\hat{r} + \delta}}$ （逐元素应用操作）
- (8) 应用更新： $\theta \leftarrow \theta + \Delta\theta$
- (9) 若满足终止条件，输出 θ ，否则跳转步骤 (2)。

4.3 线性阵列诊断模型建模

思考一个有 L 个元素的线性数组，其中元素位置分别用 $d_i (i = 1, \dots, L)$ 表示；因此该阵列在法向方向 θ_m 上的远场辐射数据能被表示为

$$z(\theta_m) = \sum_{i=1}^L e^{j \frac{2\pi f d_i \sin(\theta_m)}{c}} x_i + n_m \quad (4-5)$$

其中 c 表示光速， f 表示天线阵列的工作频率， x_i 表示第 i 个阵列元件的激励， n_m 是在 θ_m 处测量到的噪声。

如果该阵列是具有 k 个元素的平面阵列，其中 d_i^x 与 d_i^y 是其 i 个元素的坐标，则在俯仰角 θ_m 与方位角 ϕ_w 处观察到的平面阵列的远场辐射方向图可表示为

$$\psi(m, w) = d_i^x \sin(\theta_m) \cos(\phi_w) + d_i^y \sin(\theta_m) \sin(\phi_w) \quad (4-6)$$

$$z(\theta_m, \phi_w) = \sum_{i=1}^K e^{j \frac{2\pi f \psi(m, w)}{c}} x_i + n_{(m, w)} \quad (4-7)$$

从以上等式可知，这是阵列的辐射数据与元素位置之间的复杂非线性关系，假设失效原件的激励为 0，则第 i 个实例的第 j 个元素的指标 y_i^j 为 1，反之为 0。把远场辐射数据作为特征值，把元素的指标作为标签数据；根据迁移学习概念，能有以下定义：

源域： $D_s = \{Z_s^i, Y_s^i\}_{i=1}^{N_s}$ ，其中 $Z_s^i = [z_i(\theta_1), z_i(\theta_2), \dots, z_i(\theta_m)]$, $Y_s^i = [y_i^1, y_i^2, \dots, y_i^K]$

目标域： $D_t = \{Z_t^i, Y_t^i\}_{i=1}^{N_t}$ ，其中 $Z_t^i = [z_i(\theta_1, \phi_1), z_i(\theta_2, \phi_2), \dots, z_i(\theta_m, \phi_w)]$, $Y_t^i = [y_i^1, y_i^2, \dots, y_i^K]$

学习任务： $T = \{Y, f(Z)\}$

之后可以定义基于 D_s 的学习任务 T_s 和基于 D_t 的学习任务 T_t 。提出的阵列失效阵元诊断方法首先是学习非线性函数 $f_s(\cdot)$ ；然后通过将知识从 D_s 迁移到 D_t 上，从而只用少量的数据集学习 $f_t(\cdot)$

为了说明可以通过转移现有阵列失效诊断模型中的一些知识来有效地训练新阵列的诊断模型，首先将基于线性阵列的 DNN 诊断模型作为基础模型进行训练。然后，基础模型被重用训练另一个诊断模型，以在少量训练数据上确定平面阵列的失效元件的位置。

本课题中由于远场辐射数据 Z_s^i 是包含 M 个元素的复数向量，因此向量的实部被用作输入层中 M 个神经元的输入，而虚部被作为 $M+1$ 至 $2M$ 个神经元的输入；以元素 Y_s^i 的失效指标作为输出，一个 DNN 分类器能表示为

$$Y_s = f_s([Re(Z_s), Im(Z_s)]). \quad (4-8)$$

其中选择交叉熵代价函数当作学习规则, Sigmoid 作为最后一层(全连接层)的激活函数(因为 Sigmoid 输出在 0 到 1 之间, 适合二分类问题)。如果输出大于 0.5, 对应的阵元将被判定为失效阵元, 反之为非失效阵元。用 t 表示标签, 用 \hat{t} 表示预测值, 二进制交叉熵代价函数被表示为:

$$L_{Binary-cross-entropy} = -t \log \hat{t} - (1 - t) \log (1 - \hat{t}) \quad (4-9)$$

下表 4-1 展示了该基础神经网络的具体配置。

表 4-1 线性阵列诊断模型参数

层类别	神经节点数/dropout	激励函数
输入层	182	Relu
全连接层	128	Relu
全连接层	80	Relu
全连接层	64	Relu
Dropout	0.2	
全连接层	50	Sigmoid

4.4 深度迁移网络的构建

本节提出了一种用于平面阵列失效阵元诊断的深层迁移网络的新框架, 框架由三个部分组成: 域划分, 模型迁移和权值微调。

(1) 域划分是将目标域划分为几个子域, 每个子域都具有与源域相同的维度。由于平面阵列的辐射数据依据于俯仰角与方位角但线性阵列的辐射数据仅依赖与俯仰角; 因此子域的数量等于方位角的数量。这样划分域的原因有二: 1) 由于平面阵列的特征尺寸始终大于线性阵列的特征尺寸, 因此如果改变输入神经元的数量以使其适合基本模型的输入神经元, 则诊断准确性会降低。2) 线性阵列的辐射数据可以认为是从相同的方位角测量的, 而平面阵列的辐射数据是从不同的方位角测量的。从每个不同的方位角测得的数据被视为一个子域。

(2) 提出的深度迁移网络框架是一种基本迁移网络学习框架。它基于这样的假设, 即神经网络类似于一种抽象过程。网络的前层可以被当作特征提取器, 提取的特征是通用的^[9]。模型迁移是将知识从训练好的线性阵列基本模型迁移到平面阵列。由于深层网络的最后一层是决策层, 因此针对平面阵列提出的深层迁移模型将重用基础模型各层(最后一层除外)。

(3) 微调是进行深度迁移学习的常用技术。微调有两种常规操作: 一种是冻

结传输模型参数，而仅训练新添加的一层或者两层参数，另一种是训练目标域上的所有参数。在提出的框架中，增加了两个新层，并使用平面阵列的少量辐射数据训练了整个深度传输网络的所有参数。由于每个子域可以确定同一平面阵列的一组失效阵元的位置，因此添加的层也可以视为由每个子域确定的所有失效阵元位置集合的加权组合。直观地，由多个诊断结果的加权组合确定的诊断准确性高于直接诊断结果。

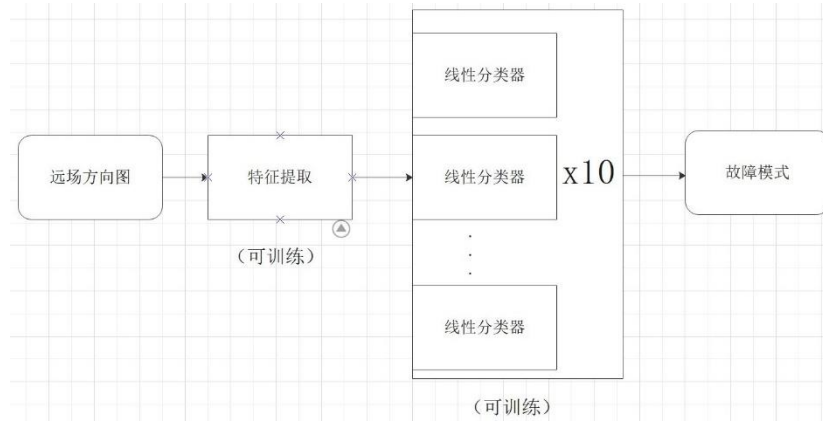


图 4-3 迁移学习方法流程

4.5 模型可视化

通过 Tensorboard 可视化，可以生成传统 DNN 诊断模型与深度迁移模型的流程图，从而方便地观察输入输出的变化以及各个层之间的关系。

下图 4-4 展示了未进行迁移直接用传统 DNN 构建的诊断模型。

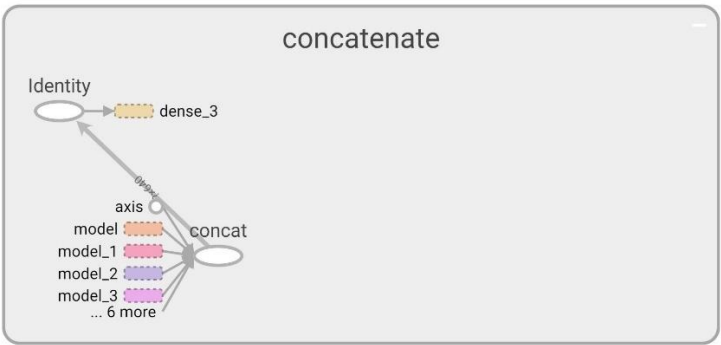


图 4-6 子域融合层

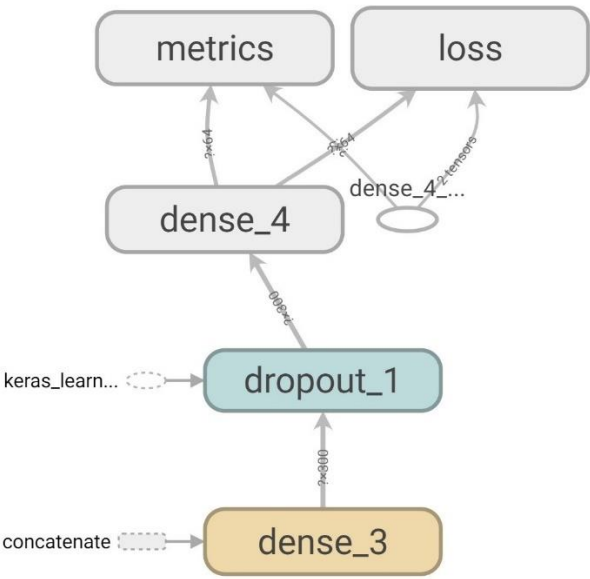


图 4-7 深度迁移网络

4.6 评估测试




图 4-8 考虑互耦的 64 单元天线平面阵

待诊断的阵列为上图 4-8 所示的考虑互耦的 64 单元天线平面阵。考虑失效单元不超过 7 个的情况，使用远场方向图对阵列天线进行诊断。输出标签为 64 维的二进制向量。

线性阵列的远场方向图数据是从 -90° 到 90° 以 2° 的间隔进行采样，而平面阵列的远距辐射方向图数据是从 -90° 至 90° 并以 2° 俯仰角间隔，从 0° 到 180° 以 20° 的方位角间隔采样。所以方向图维度为 910 个采样点，将实部虚部分开后，输入数据变为 1820 维。

针对不同的失效阵元情况每种随机生成 1000 个远场辐射方向图实例。随机选择 80% 的数据集作为训练数据，其余作为测试数据。为了消除每个维度数据之间的偏差，对所有数据进行了标准化。

首先对每一种模式进行编号，因为有 8 种失效情况（包括无故障），每种情况随机有 1000 个远场方向图实例，因此共有 8000 种模式，将失效阵元诊断作为多分类多标签问题即需要分出 8000 类。

针对此问题搭建的神经网络模型，如图 4-9 所示。为了提取输入的主要特征，首先将 CNN 卷积层重复使用 3 次，然后经过 Dropout 层削弱过拟合，之后经过两层全连接层改变输出值的维度使其与标签的维度相等，最后因为是多标签多分类问题，每个阵元都是独立的失效或者工作，所以使用 Sigmoid 的作为输出层的激活函数；大于 0.5 视为工作，否则为失效。

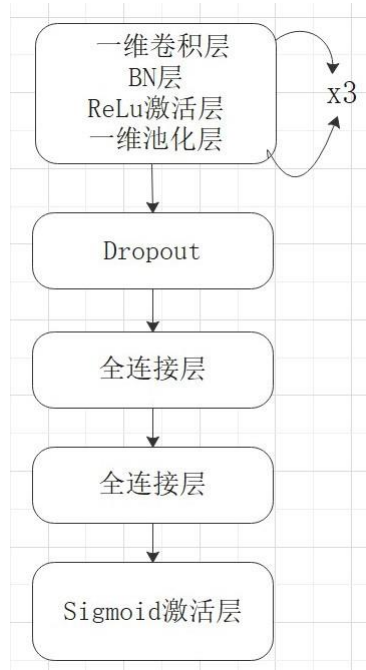


图 4-9 神经网络结构

训练过程中，样本数据为 8000 种情况的远场方向图。训练中优化算法使用 Adam，其中步长 $\epsilon=0.01$ ，指数衰减速率 ρ_1 和 ρ_2 分别为 0.9 和 0.999，数值稳定的

常数 $\delta=10^{-8}$ ，每批次样本为 50，代价函数使用交叉熵。

首先需要证实构建的深度迁移网络对阵列诊断的有效性和可行性。下图 4-10 与 4-11 展示了迁移网络在随机采样的训练集与测试集上的表现。从图中可看出随着训练轮数的增加，重建激励与真实激励之间的 Cross Entropy Error(CEE)总体在减小且诊断准确率逼近 1。即使训练中出现了一些波动，但也很快恢复，从而证明了深度迁移模型构建的可行性。




图 4-10 迁移网络在训练与测试集上的 CEE




图 4-11 迁移网络在训练与测试集上的诊断准确度

下图 4-12 与 4-13 分别展示了传统 DNN 模型与新构建的迁移模型在训练集与测试集上的表现。从图中可以看出，与传统 DNN 模型相比，深层迁移网络能使用更少的时间来达到更好的效果。不论在训练集上还是测试集上，深层迁移网络均使用更短的时间达到了更低的 CEE 与更好的诊断准确度；但因为训练集有更多的样本，因此训练集上的表现效果均好于在测试集上的表现效果，这是可以预见的。也因此证明了迁移后的新网络比传统 DNN 有更好的诊断性能。




图 4-12 两种模型在训练集上的 CEE 与准确度




图 4-13 两种模型在测试集上的 CEE 与准确度

在评估完 CEE 与准确度后，本节也额外统计了测试集中每种失效情况下的诊断正确的样本数量；只有输出端的每个神经元都与标签匹配时，才算正确，否则为失效。如下图 4-14 和 4-15 所示。




图 4-14 30%训练集诊断表现




图 4-15 80%训练集诊断表现

测试集样本一共有 2400 个，每种失效情况的样本为 300 个，共八种失效情况。

从上图可明显得出训练集的大小和失效阵元个数对诊断正确样本个数有着明显的影响。当训练集增大时，每种失效阵元情况下诊断正确的样本个数都有增加；且不论在哪种训练集下，阵元失效越多，诊断正确的样本个数就越少；这也意味着失效阵元数量多的情况相比于失效阵元少的情况更难被训练，网络更难成型，从而导致了诊断正确的样本个数较少。

第五章 研究工作总结

本文首先介绍了机器学习的一些基础和基本理论,然后分析了天线阵列中阵元失效对天线辐射性能的影响;然后介绍了当前各种基于远场方向图诊断失效阵元方法,比较了它们的优劣。之后提出了一种新的用于天线失效阵元诊断的深度迁移学习框架。与现有的机器学习诊断方法相比,该方法可以通过迁移训练后的基础模型中的一些知识,以较少的训练数据准确地实现诊断;并消耗更少的时间且具有更高的准确率。

纵览全文,本文的研究内容和工作如下:

- 1.介绍了机器学习与阵列综合的基本理论和基础;
- 2.分析了天线阵列中阵列失效对方向图的影响;
- 3.研究了如何利用线阵列基本网络在平面阵列上进行域划分并构建深度迁移网络
- 4.设计合理的学习与权值更新规则进行模拟仿真,验证了该方法诊断失效元件的可行性。

目前存在的可改进的地方以及对下一步工作的展望:

- 1.迁移学习在阵元失效诊断模型中的应用还有待优化,过拟合的情况任存在,是否应加入正则化以应对过拟合,优化器的学习率动态变化是否有更好的仿真表现,这些问题还没有考虑到。
- 2.将诊断算法应用扩展到其他形式的更大型阵列,也是应该考虑并展开工作的方向。

致谢

本论文的工作是在我的导师张瑛老师指导下完成的。

由于今年突然爆发的新冠疫情，导致我并不能回到学校完成毕设，但张瑛老师仍然通过及时通讯软件和我交流来指导我的毕业设计，见我遇到困难还让师姐来帮忙和支持完成我的毕设，在她们的帮助下，我算是磕磕绊绊完成了毕设。在此，再次感谢张瑛老师和学姐对我的帮忙和关怀！没有她们的改善性意见，我可能真的完不成毕设，对于我这个电工小白来说，关于电磁场方面的知识本来就难。

最后，还要感谢我引用的参考文献的作者和评阅本论文的老师，没有前人的付出，后人哪能乘凉，正是站在巨人的肩膀上我才能完成此论文！

参考文献

- [1] G. Oliveri, P. Rocca, and A. Massa, "Reliable diagnosis of large linear arrays—A Bayesian compressive sensing approach," *IEEE Trans. Antennas Propag.*, vol. 60, no. 10, pp. 4627–4636, Oct. 2012.
- [2] H. Zhao, Y. Zhang, J. Hu, and Z. Chen, "Hybrid sparse reconstruction method of moments for diagnosis of wire antenna arrays," *Applied Computational Electromagnetics Society Journal*, vol. 32, no. 10, pp. 882–887, Oct 2017.
- [3] Y. Zhang and W. Wang, "Robust Array Diagnosis Against Array Mismatch Using Amplitude-Only Far Field Data," in *IEEE Access*, vol. 7, pp. 5589–5596, 2019.
- [4] Oliveri, Giacomo , P. Rocca , and A. Massa . "Failure detection in large arrays through bayesian compressive sensing." *European Conference on Antennas & Propagation I* IEEE, 2013
- [5] H.Zhao,Y.Zhang,E.-P.Li,A.Buonanno,andM.D'Urso, "Diagnosis of array failure in impulsive noise environment using unsupervised support vector regression method," *IEEE Trans. Antennas Propag.*, vol. 61, no. 11, pp. 5508–5516, Nov 2013.
- [6] A. Patnaik, B. Chowdhury, P. Pradhan, R. K. Mishra, and C. Christodolou, "An ANN application for fault finding in antenna arrays," *IEEE Trans. Antennas Propag.*, vol. 55, no. 3, pp. 775–777, Mar. 2007.
- [7] N. V. S. N. Sarma and D. Vakula, "A Method for Diagnosis of Current Faults in Antenna Arrays Using Neural Networks," *International Journal of RF and Microwave Computer-Aided Engineering*, 2008.
- [8] D. Vakula and N. Sarma. "Neural network approach to diagnose phase shifter faults of antenna arrays." *International Conference on Electromagnetic Interference & Compatibility IEEE*, 2006.
- [9] Tan, Chuanqi , et al. "A Survey on Deep Transfer Learning." (2018).
- [10] 庄福振,罗平,何清,史忠值.迁移学习研究进展.软件学报,2015,26(1):26-29.
- [11] 朱赛,蔡金燕,韩春辉,等.失效阵元对阵列天线性能影响分析[J].电光与控制,2019,26(8):54-59
- [12] 洪佳明,印鉴,黄云,等. TrSVM:一种基于领域相似性的迁移学习算法[J]. 计算机研究与发展, 2011(10):31-38.
- [13] 吉阳,任宏滨,简金蕾,等. 基于相控阵引信的自适应起爆控制算法[J].电光与控制,2017,24(5):65-67
- [14] 束咸荣, 何炳发, 高铁. 相控阵雷达天线[M].国防工业出版社,2007
- [15] B. Yeo and Y. Lu, "Array failure correction with a genetic algorithm," *IEEE Trans. Antennas Propag.*, vol. 47, no. 5, pp. 823–828, 1999. [1] A. Patnaik, B. Choudhury, P. Pradhan, R. K. Mishra, and C. Christodoulou, "An ANN application for fault finding in antenna arrays," *IEEE Trans. Antennas Propag.*, 2007, vol. 55, no. 3, pp. 775–777
- [16] Migliore D. A Compressed Sensing Approach for Array Diagnosis From a Small Set of Near-Field Measurements[J]. *Antennas and Propagation, IEEE Transactions on*, 2011, 59(6):2127–2133
- [17] 邵江达. 平面近场测量的“诊断”技术[J]. 现代雷达,1997,(4):56-61
- [18] 王玲玲, 方大纲. 运用遗传算法结合 FFT 进行多单元失效阵列校准[J]. 电波科学学报, 2005,20(5):561–565

- [19] Xu N, Christodoulou C G, Barbin S E, et al. Detecting failure of antenna array elements using machinelearning optimization[C].Antennas and PropagationSociety InternationalSymposium, 2007,5753-5756
- [20] Collobert R, Bengio S, Williamson C. SVMTorch: Support Vector Machines for Large-Scale RegressionProblems[J].JournalofMachineLearningResearch,2001,1(2):143--160
- [21] Y. Hajilou, H. R. Hassani, B. Rahmati. Mutual coupling reduction between microstrip patch antennas[C].6thEuropeanConferenceonDigitalObjectIdentifier.Prague,2012,1-4
- [22] 汪一心, 朱桓, 徐晓文等. 阵列有源天线单元失效的影响与补偿[J]. 现代雷达, 1998, (4):58-62
- [23] 高铁, 王金元等. 二维固态有源相控阵失效单元补偿新方法[J]. 现代雷达, 2002, 24(2) 71-75
- [24] 边莉, 车向前, 江晓林.Taylor 阵列双阵元失效校正算法[J]. 黑龙江科技学院学报, 2013, 23(3):302-307
- [25] 尚军平. 相控阵天线快速测量与校准技术研究[D].西安: 西安电子科技大学, 2010
- [26] SHANG J, LI X, SUN L, et al. A novel fast measurement method and diagnostic of phased array antennas[C]. Internatonal Symposium on Antennas, 2012: 219-222.
- [27] RODRI GUEZ-GONzALEZ J A, ARE PENA F, FERNANDE2 DELGAD0 M , et al . Rapid method for finding faulty elements in antenna arrays using far field pattern samples[J]. IEEE Transactions on Antennas and Propagation, 2009, 57(6): 1679—168
- [28] MALLAHZADEH A, TAHERZADEH M. Investigation of a proposed ann-based array antenna diagnosis technique on a planar micrstrip arr[J]. Applied Computational Electromagnetics Society Journal, 2011, 26(8): 667.
- [29] YEO B K, LU Y. Expeditious diagnosis of line ararray failure using support vector machine with low degree polynomial kernel[J]. IET Microwaves Antennas& Propagation, 2012, 6(13): 1473—1480
- [30] Srinivas M, PATNAILKLM. Adaptive probabilities of crossover and mutation in genetic algorithms[J].IEEETransactiononSystem,ManandCybernetics,1994,24(4):656-667
- [31] 王思艳. 自适应遗传算法的研究[D].华北电力大学（河北）,2009.
- [32] 任子武,伞冶. 自适应遗传算法的改进及在系统辨识中的应用研究[J].系统仿真学 报,2006,18(1):41-66

外文资料原文

REVIEW

doi:10.1038/nature14539

Deep learning

Yann LeCun^{1,2}, Yoshua Bengio³ & Geoffrey Hinton^{4,5}

Deep learning allows computational models that are composed of multiple processing layers to learn representations of data with multiple levels of abstraction. These methods have dramatically improved the state-of-the-art in speech recognition, visual object recognition, object detection and many other domains such as drug discovery and genomics. Deep learning discovers intricate structure in large data sets by using the backpropagation algorithm to indicate how a machine should change its internal parameters that are used to compute the representation in each layer from the representation in the previous layer. Deep convolutional nets have brought about breakthroughs in processing images, video, speech and audio, whereas recurrent nets have shone light on sequential data such as text and speech.

Machine-learning technology powers many aspects of modern society: from web searches to content filtering on social networks to recommendations on e-commerce websites, and it is increasingly present in consumer products such as cameras and smartphones. Machine-learning systems are used to identify objects in images, transcribe speech into text, match news items, posts or products with users' interests, and select relevant results of search. Increasingly, these applications make use of a class of techniques called deep learning.

Conventional machine-learning techniques were limited in their ability to process natural data in their raw form. For decades, constructing a pattern-recognition or machine-learning system required careful engineering and considerable domain expertise to design a feature extractor that transformed the raw data (such as the pixel values of an image) into a suitable internal representation or feature vector from which the learning subsystem, often a classifier, could detect or classify patterns in the input.

Representation learning is a set of methods that allows a machine to be fed with raw data and to automatically discover the representations needed for detection or classification. Deep-learning methods are representation-learning methods with multiple levels of representation, obtained by composing simple but non-linear modules that each transform the representation at one level (starting with the raw input) into a representation at a higher, slightly more abstract level. With the composition of enough such transformations, very complex functions can be learned. For classification tasks, higher layers of representation amplify aspects of the input that are important for discrimination and suppress irrelevant variations. An image, for example, comes in the form of an array of pixel values, and the learned features in the first layer of representation typically represent the presence or absence of edges at particular orientations and locations in the image. The second layer typically detects motifs by spotting particular arrangements of edges, regardless of small variations in the edge positions. The third layer may assemble motifs into larger combinations that correspond to parts of familiar objects, and subsequent layers would detect objects as combinations of these parts. The key aspect of deep learning is that these layers of features are not designed by human engineers: they are learned from data using a general-purpose learning procedure.

Deep learning is making major advances in solving problems that have resisted the best attempts of the artificial intelligence community for many years. It has turned out to be very good at discovering

intricate structures in high-dimensional data and is therefore applicable to many domains of science, business and government. In addition to beating records in image recognition¹⁻⁴ and speech recognition⁵⁻⁷, it has beaten other machine-learning techniques at predicting the activity of potential drug molecules⁸, analysing particle accelerator data^{9,10}, reconstructing brain circuits¹¹, and predicting the effects of mutations in non-coding DNA on gene expression and disease^{12,13}. Perhaps more surprisingly, deep learning has produced extremely promising results for various tasks in natural language understanding¹⁴, particularly topic classification, sentiment analysis, question answering¹⁵ and language translation^{16,17}.

We think that deep learning will have many more successes in the near future because it requires very little engineering by hand, so it can easily take advantage of increases in the amount of available computation and data. New learning algorithms and architectures that are currently being developed for deep neural networks will only accelerate this progress.

Supervised learning

The most common form of machine learning, deep or not, is supervised learning. Imagine that we want to build a system that can classify images as containing, say, a house, a car, a person or a pet. We first collect a large data set of images of houses, cars, people and pets, each labelled with its category. During training, the machine is shown an image and produces an output in the form of a vector of scores, one for each category. We want the desired category to have the highest score of all categories, but this is unlikely to happen before training. We compute an objective function that measures the error (or distance) between the output scores and the desired pattern of scores. The machine then modifies its internal adjustable parameters to reduce this error. These adjustable parameters, often called weights, are real numbers that can be seen as 'knobs' that define the input-output function of the machine. In a typical deep-learning system, there may be hundreds of millions of these adjustable weights, and hundreds of millions of labelled examples with which to train the machine.

To properly adjust the weight vector, the learning algorithm computes a gradient vector that, for each weight, indicates by what amount the error would increase or decrease if the weight were increased by a tiny amount. The weight vector is then adjusted in the opposite direction to the gradient vector.

The objective function, averaged over all the training examples, can

¹Facebook AI Research, 770 Broadway, New York, New York 10003 USA. ²New York University, 715 Broadway, New York, New York 10003, USA. ³Department of Computer Science and Operations Research Université de Montréal, Pavillon André-Aisenstadt, PO Box 6128 Centre-Ville STN Montréal, Québec H3C 3J7, Canada. ⁴Google, 1600 Amphitheatre Parkway, Mountain View, California 94043, USA. ⁵Department of Computer Science, University of Toronto, 6 King's College Road, Toronto, Ontario M5S 3G4, Canada.

外文资料译文

深度学习:

作者: Yann LeCun, Yoshua Bengio, Geoffrey Hinton

摘要:

深度学习是指能够令由多个处理层组成的计算机模型以多层抽象的方式去学习数据的表达。这些方法使得一些前沿领域诸如语音识别, 视觉物体识别, 目标检测以及其他包括药物发现和基因组学等都有了极大地发展。深度学习使用反向传播(BP)算法, 指出了机器应该如何改变其内部用于计算每一层对于上一层的表示的参数, 从而可以发现在大型数据集中的复杂结构。深度卷积网络给处理图像、视频、语音和音频的领域带来了突破, 而递归网络对于连续的数据例如文本和语音有很好的性能。

机器学习技术为现代社会的许多领域提供了强有力的支持: 从网站搜索到社交网络的内容过滤再到电子商务网站的建议, 并且它越来越多地出现在相机和智能手机等消费电子产品中。机器学习系统被用于分辨图像中的目标, 将语音转换成文本, 根据用户的兴趣选择新闻内容、广告或者产品, 并选择相关的搜索结果。这些应用程序越来越广泛地使用一系列叫做深度学习的技术。

传统的机器学习处理原始数据的能力是有限的。几十年来, 构造一个模式识别或机器学习系统需要细致的组织和专业的知识去设计一个特征提取器来完成将原始数据转换成一个合适的内部表示或特征向量, 这当中的子系统通常是一个分类器, 可以完成对输入样本的检测或分类。

表示学习是一系列学习的方法, 它允许向机器输入原始数据, 能够自动发现用于检测或分类所需的特征表示。深度学习方法就是一种拥有多层表示特征的学习方法, 在每一层中通过简单但是是非线性的模块将一个层级的数据(以原始数据开始)转换到更高层次, 更抽象的表达形式。通过足够多的转换, 即使非常复杂的函数也可以被学习到。对于分类任务, 更高层次的表示可以放大输入的区别并且抑制无关的变化。例如, 对于一幅图像来说, 以像素值矩阵的形式输入, 在第一层中被学习的往往是在图像中某些特定方向或位置边缘存在与否的特征。第二层往往是根据提取边界的走向来检测图案, 而忽略边缘位置的细小变化。第三层可能是将图案组合成更大的组合图案, 从而与相似的目标部分对应, 并且随后的层会将这

些部分再联合从而构成检测的目标。深度学习的关键方面在于这些层的设计不是由人类工程师完成的：它们是通过使用通用的学习算法从原始数据中学习的得到。

深度学习正在为解决多年来阻碍人工智能这一先进尝试的发展的诸多问题上发挥重要作用。它被证实已于发现高维数据的复杂结构，因此适用于科学、商业和管理等很多领域。除了打破图像识别和语音识别的很多记录外，它在诸如预测潜在药物分子的活性，分析粒子加速的数据，重新构建大脑回路以及预测非编码基因序列突变对基因表达和疾病的影响等领域打败了其他机器学习的技术。或许更令人惊讶的是，深度学习在自然语言理解方面的各种课题上也形成了极好的成果，特别是在主题分类，情感分析，问题回答和语言翻译上。

我们认为深度学习在不远的将来会有更大的成功，因为它需要很少的人工干预，所以它可以很容易地利用好计算能力和数据量的提升。目前正在为深度神经网络而开发的新的学习算法和结构只会加快这一进程。

监督学习：

最常见的机器学习的形式，就是监督学习，不管其是否是深度的。试想我们建立一个可以对输入的图片中包含的东西进行分类的系统，包括人、车子、房子、宠物等等。我们首先需要建立带有对应类别标签的图片的巨大数据集。在训练过程中，机器被给与一张图片，就会输出一个其对于所有类别的得分构成的向量。我们想要让所期望的类对应最高的分数，但是在训练之前这是不太可能的。我们利用衡量误差（或距离）的目标函数来计算实际输出分数与期望的样本分数之间的差距。机器通过修改它内部的可调节的参数使得误差减小。而这些可调节的参数，通常称为权重，是可见的“旋钮”，真正决定了输入输出之间的函数关系。在一个典型的深度学习系统中，会有数百万个这样的可调节的权重，和数百万用来训练的带有标签的样例

为了恰当地调整权重向量，学习算法计算了每个权值的梯度向量，表示如果权值增加了一个很小的量，那么误差就会增加或减少的量。然后，权值向量就需要在梯度矢量的相反方向上进行调整。

平均了所有样本的目标函数，可以看作是一种在权值的高维空间上的丘陵地形。负的梯度向量方向表示地形中下降最快的方向，地形上越接近它的最小值，也就取得了平均上的最小误差。

在实践中，大部分开发者都会采用随机梯度下降（SGD）的方法。它包括提取一组训练样本向量作为输入，计算输出和误差，还有这些样本的平均梯度，并且据此调整权重。不断地从训练集中获取一部分训练样本来重复这一过程，直到目标函数的平均值不再下降。它被称作随机，是因为每一个小的样本集对于全体样本平均梯度的估计来说都会产生噪声，相较于一些精细的优化方法，这个简单的过程往往会很快地找到一组好的权重。在训练完成后，系统的性能通过测试集来测试，即测试系统的泛化能力——也就是它对于训练过程中未见过的新样本的正确预测能力。

许多当前实际应用中的机器学习在人工提取的特征基础上使用线性分类器进行分类，一个二分类的线性分类器会计算特征向量各元素的加权和，若其高于阈值，那么输入就会被分类为一个特定的类别。

自从二十世纪九十年代以来，我们就知道一个线性分类器仅仅能通过一个超平面将输入空间分成几个简单的区域。但是图像或语音的识别问题等，要求输入-输出函数对于诸如位置，目标的光照和旋转，或者语音中音高和音色等的变化此类不相关的输入是不敏感的，而对一些特定的微小变化十分敏感，例如我们希望能够区分一只白色的狼和一只很像狼的萨摩耶犬。在像素层面上，在不同环境中不同姿势的两只萨摩耶的图片或许都会有很大的不同，然而相同背景中同样位置的一只萨摩耶和一只狼却会很像。线性的分类器，或者其他的直接在像素上操作的浅层分类器就算能够将前两个分为同一类，也很有可能不能地区分出后两个。这就是什么浅层分类器需要很好的用于解决选择不变问题的特征提取器——一个能够提取出图像中区分目标的那些关键特征，但是这些特征对于分辨动物的姿势就无能为力了。为了使分类器更强大，可以使用通用的非线性特征，如核方法，但是诸如通过高斯核产生的这些通用特征，不能使学习对象具有对于所有的训练样本都很好的泛化效果。传统的选择是人工去设计好的特征提取器，而这需要大量的工程技能和专业经验。通过使用通用目标的学习过程，可以自动学习到好的特征，从而避免上述问题。这是深度学习的关键优势。